




MML_DAY1

关键组件

1. 数据

- 定义：机器学习的“原料”，由一个个样本组成。每个样本包含描述属性的特征（必须），以及模型需要预测的标签（可选，视学习类型而定）。
- 深度学习：相比传统方法需要固定长度的特征向量，深度学习的一大优势是能够处理变长数据（如不同长度的文本、不同尺寸的图像），且通常需要海量数据才能发挥效能。
- 关键点：数据的**质量**至关重要。若数据包含错误、不均衡或社会偏见，会导致模型无效或产生偏见。

2. 模型

- 定义：负责将输入数据转换为输出结果的计算机制或数学函数。
- 深度学习：特指由**多层神经网络**错综复杂地交织在一起的模型。它通过层层数据转换，能够捕捉传统方法无法处理的复杂特征。
- 关键点：模型是机器学习的核心主体，其复杂程度决定了能解决问题的难度上限。

3. 目标函数

- 定义：用于量化模型优劣的指标，通常被称为**损失函数**，目标是通过算法将其优化到最小值。
- 深度学习：在深度学习训练中，这是指导神经网络参数调整的唯一“指挥棒”。
- 关键点：

- 类型：预测数值常用平方误差，分类问题常用错误率（或交叉熵）等。
- 评估：需警惕**过拟合**现象，即模型在训练集（模拟考）表现好，但在测试集（期末考）表现差。

4. 优化算法

- 定义：用于搜索最佳模型参数，以最小化目标函数的具体计算方法。
- 深度学习：绝大多数深度学习模型都基于**梯度下降** (Gradient Descent) 及其变体算法。
- 关键点：它是一个迭代过程，通过不断计算损失函数下降的方向，一步步微调参数，直到找到最优解。

分类

监督学习

核心：利用“特征-标签”对进行训练，学习从输入到输出的映射。

- 回归：预测连续的数值（如：房价、降雨量）。
- 分类：预测离散的类别（如：猫/狗、手写数字）。
- 标记问题：多标签分类，类别不互斥（如：文章的多个标签）。
- 搜索与推荐：预测排序或偏好分数（如：网页排名、商品推荐）。
- 序列学习：输入或输出是变长的序列（如：机器翻译、语音识别）。

无监督学习

核心：只有特征没有标签，旨在发现数据内在的结构或模式。

- 聚类：自动分组相似数据（如：用户分群）。
- 主成分分析 (PCA)：数据降维与压缩，捕捉核心属性。
- 因果关系与图模型：发现变量间的逻辑或概率关系。
- 生成对抗网络 (GANs)：学习数据分布以生成新的合成数据。

自监督学习

核心：介于监督与无监督之间。利用海量无标签数据，通过 **破坏数据** → **预测还原**（如掩码、加噪）的方式构造伪标签进行训练。

- 作用：学习数据的底层表征和规律（语法、结构）。
- 应用：作为大模型（如ChatGPT、BERT）的预训练阶段，或用于生成式模型（如Diffusion）。

强化学习

核心：智能体 (Agent) 在与环境的交互中学习。

- 机制：观察状态 →→ 执行动作 →→ 获得奖励/惩罚。
- 目标：学习一个策略（Policy），以最大化长期的累积奖励（如：下围棋、机器人控制）。

梯度向量

求导：对于每个参数，如果我们把这个参数增加或减少一个无穷小的量，可以知道损失会以多快的速度增加或减少。如果 f 在一个区间内的每个数上都是可微的，则此函数在此区间中是**可微(可导)**的。

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

偏导数：在深度学习中，函数通常依赖于许多变量。因此，我们需要将微分的思想推广到多元函数上。设 $y = f(x_1, x_2, \dots, x_n)$ 是一个具有 n 个变量的函数。 y 关于第 i 个参数 x_i 的偏导数为，**此时将其他变量视为常量**。

$$\frac{\partial y}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_{i-1}, x_i + h, x_{i+1}, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}$$

梯度：对一个多元函数的每一个变量求偏导数，可得到一个**向量(梯度)**：

$$\nabla_{\mathbf{x}} f(\mathbf{x}) = \left[\frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]^T$$

- 梯度方向：表示函数上升最快方向
- 梯度反方向：表示函数下降最快方向
- 梯度大小：表示变化率

链式法则

用于计算复合函数（即函数套函数）的导数。核心是将复杂的求导分解为多个简单求导的乘积（就像传话游戏，一层层传导）。

假设 $y = f(u)$ 且 $u = g(x)$ ，则：
$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$$


举例：

求 $y = (3x)^2$ 的导数。

1. 拆解：令 $u = 3x$ ，则 $y = u^2$
2. 分步求导： $\frac{dy}{du} = 2u$ ， $\frac{du}{dx} = 3$
3. 相乘： $\frac{dy}{dx} = 2u \cdot 3 = 6u$
4. 还原：将 $u = 3x$ 代回，得 $18x$

反向传播

如下图所示，这个是一个两层的网络，其中保证 h_1, h_2 的激活函数和 y 损失函数都是可微的，并且损失函数有极小值。反向传播过程：



- 使用链式法则求得**梯度**，最终输出(损失函数 y)和权重的导数，其中 b 是偏置

$$\frac{\partial y}{\partial w_1}, \frac{\partial y}{\partial w_2}, \frac{\partial y}{\partial w_3}, \frac{\partial y}{\partial w_4}, \frac{\partial y}{\partial w_5}, \frac{\partial y}{\partial w_6}, \frac{\partial y}{\partial b},$$

- 确定学习率 R
- 更新每个参数，使得损失函数往变得更小。假设 y 对 w 的导数为正，那么 w 变小 y 变小，所以应该减去正值。反之应该减去一个负值，所以求导的结果的正负号，指明了权重变化方向。调整的步长由学习率和优化器决定。

$$\begin{aligned} w_{1,new} &= w_{1,old} - \frac{\partial y}{\partial w_1} * R \\ w_{2,new} &= w_{2,old} - \frac{\partial y}{\partial w_2} * R \\ w_{3,new} &= w_{3,old} - \frac{\partial y}{\partial w_3} * R \\ &\dots \end{aligned}$$