

MML_DAY2

深度学习基本原理

线性代数基础概念

标量：一个单独的值

向量：一系列数，可以在多维空间中表示一个点，带方向，从零点指向该点

向量基本运算：

$$\begin{aligned}A + B &= B + A \\A * B &= B * A \\ \cos \theta &= \frac{A * B}{|A| \cdot |B|}\end{aligned}$$

矩阵：一组二维数据，通常使用 $n * m$ 表示n行m列

矩阵常用计算：

$$\begin{aligned}A * (B + C) &= A * B + A * C \\A * (B * C) &= (A * B) * C \\A^T &(\text{转置, 行列互换})\end{aligned}$$

张量：多维矩阵，通常使用 $c_1 * c_2 * c_3 * \dots$ 表示张量的维度，深度学习中数据基本都是以张量的形式存在，本质计算还是矩阵运算。

深度学习训练框架

模型结构：相当于确定公式，根据合适的问题合适的公式，例如：线性公式永远不可能完美拟合非线性数据

模型初始化：初始化参数有助于加速模型迭代，避免陷入局部最优解


前向推理：输入训练样本X推导得到y

损失函数：衡量 Y 和 Y_{pred} 的差距的公式，必须具有：可微，存在最小值等属性。

梯度下降：通过链式法则计算损失函数和各个参数的导数，在通过学习率和优化器计算迭代步长，更新模型权重，使得损失函数值变小的过程。

梯度爆炸：通常指训练过程中，权重更新步长过大，导致损失函数不减反增。进一步导致更新步长变的更大，模型参数不断恶化的过程。

梯度消失：通常指训练过程中，梯度步长几乎为0的情况，但是损失函数和模型准召率不足的情况，可能陷入局部最优解的情况。



注意：Epoch，Batch，Step的关系。

- Epoch：整个训练集完整过一遍，完成训练需要训练Epoch次
- Batch：描述样本，一次送入模型的一批样本
- Step：描述动作，处理一个 batch 并进行一次参数更新

Epoch、Step、Batch 的关系




激活函数

激活函数：全连接层单元输入和输出的变化，目的是为整个网络引入非线性变化，更好的拟合数据。只用线性变换，无论叠加多少层，最终的数学表达式都可以化简为 $y = Wx + by = Wx + b$ ，相当于多层网络失去了意义。激活层一般没有学习参数。

sigmoid


公式： $f(x) = \frac{1}{1 + e^{-x}}$



特点：保证输出在(0,1)范围内，适合用于二分类任务

Tanh


公式： $\tanh(x) = \frac{\sinh(x)}{\cosh(x)} = \frac{e^x - e^{-x}}{e^x + e^{-x}}$



特点：保证输出在(-1,1)范围内，计算量大

Relu


公式: $Relu = \max(0, x)$



特点：分段，计算量小

Gelu

公式: $GELU(x) = 0.5 \cdot x \cdot \left(1 + \tanh \left(\sqrt{\frac{2}{\pi}} \cdot (x + 0.044715 \cdot x^3) \right) \right)$



特点：在负值区域有非零的平滑过渡，而非直接置零。在 Transformer 架构（如 BERT、GPT 等）中广泛使用。

Softmax

公式: $y_k = \frac{\exp(a_k)}{\sum_{i=1}^n \exp(a_i)}$

特点：将一系列向量，转为[0,1]之间的数，并保证其和为1。常用于多分类问题的输出层

损失函数

均方差

公式：有两种，求平均和求和。

$$\ell(x, y) = \frac{1}{N} \sum_{n=1}^N (x_n - y_n)^2, \text{reduction} = \text{mean} \text{时}$$
$$\ell(x, y) = \sum_{n=1}^N (x_n - y_n)^2, \text{reduction} = \text{sum} \text{时}$$

特点：常用于回归任务(最终结果是概率)

交叉熵

公式：


$$H(p, q) = - \sum_x p(x) \log q(x)$$

特点：适用在多分类任务中，通常x需要通过softmax归一化到[0,1]之间。

例子： $x = [0.5, 0.4, 0.1]$, $p(x) = [1, 0, 0]$ ，则有

$$\begin{aligned} H(p = [1, 0, 0], q = [0.5, 0.4, 0.1]) \\ &= -(1 \cdot \log(0.5) + 0 \cdot \log(0.4) + 0 \cdot \log(0.1)) \\ &= -\log(0.5) \\ H(p, q) &= -\log(x_i), \text{其中} p_i = 1 \text{时} \end{aligned}$$

如下图所示蓝线，当 $x \in (0, 1]$ 时 $H \in (+\infty, 0]$ ，意味着目标类型的概率越低，损失函数指数级增大， $x = 1$ 时， $H = 0$ 。



CrossEntropyLoss

公式：

$$H(p, q) = - \sum_x [p(x) \log q(x) + (1 - p(x)) \log(1 - q(x))]$$

特点：用于多标签分类任务中，就是在交叉熵的基础上增加了对0概率目标的乘法。

神经网络架构


如下所示，一般由输入+若干层隐藏层+输出层组成。

- 输入:张量
- 隐藏层：线性/仿射变换 + 非线性激活函数
- 输出：：线性/仿射变换 + （可选）输出激活函数，之后接损失函数
- **网络层数更深(更重要)**：通过多层逐级组合低级特征，能表示**更抽象、更复杂**的层次化特征。
- 网络更宽：神经元数量更多空间更大，可容纳更多不同特征/模式，能同时学习**更多种**特征。

神经网络整体结构

八子子山田
盗版必究

输入层 → 若干隐藏层（全连接 + 激活） → 输出层



batch_size选择策略

- BGD: batch size = 整个训练集，1 个 step 用 全部训练数据更新参数。
 - 优点：收敛稳定
 - 缺点：更新速度慢
- SGD: batch size = 1，1 个 step 用 1 个样本更新参数
 - 优点：更新速度快
 - 缺点：收敛不稳定
- Mini-batch SGD: 1 个 step 用 一个batch的样本，更新参数，batch size = B
 - 特点：居中

批量梯度下降 (BGD)	随机梯度下降 (SGD)	小批量梯度下降 (Mini-batch SGD)
每批数据 全部训练数据	每批数据 每次 1 个样本	每批数据 每次 B 个样本
优点 梯度精确，收敛稳定	优点 更新快，可跳出局部最优	优点 折中：效率 + 稳定性
缺点 数据量大时极慢	缺点 噪声大，收敛不稳定	缺点 需要选择批大小 B

学习率选择策略

- 阶梯衰减：按固定周期把学习率突然降一档，例如：每epoch，将学习率乘以0.1。
 - 优点：是简单稳定、易调参
 - 缺点：是不够平滑，降得太早或太晚都可能影响效果。
- 余弦退火：让学习率按余弦曲线从 n_{max} 平滑下降到 n_{min} ，若采用重启机制则会周期性回升到较大学习率。
 - 优点：下降平滑，后期收敛通常更稳定。
 - 缺点：周期等参数需要设置，不合适会影响训练节奏。
- 热身(可以结合其它策略)：在训练开始时先用较小学习率，再逐步增大到目标学习率。
 - 优点：能缓解训练初期不稳定，减少梯度爆炸风险。
 - 缺点：会增加前期训练时间

Dim维度判断技巧

针对一个(B,H,W)的张量，分别对dim={0,1,2}进行softmax：

- dim=0,对应B，那么固定H和W,例如(n,0,0)
- 在(n,0,0)维度中，n取0~B，一共B个数，对这B个数进行softmax
- 依次变化H和W维度，重复上述，计算完成。

代码块

```

1  x.shape = (2, 3, 2)
2  x = torch.tensor([
3      [[1.0, 8.0],
4       [3.0, 4.0],
5       [5.0, 6.0]],
6
7      [[2.0, 1.0],
8       [4.0, 3.0],
9       [6.0, 5.0]]
10 ])
11
```

```
12 1.针对dim=0,固定 (h, w), 例如:位置 (h=0, w=0),两个batch的值是: [1,2]
13 2.softmax([1,2])=[0.269,0.731]
14 3.重复以上,可得:
15 tensor([
16     [[0.2689, 0.9991],
17      [0.2689, 0.7311],
18      [0.2689, 0.7311]],
19
20     [[0.7311, 0.0009],
21      [0.7311, 0.2689],
22      [0.7311, 0.2689]]
23 ])
```