

MML_DAY5

Attention Mask

- 类别：常见的attention类似如下所示，区别在于 $Q * K^T$ 的结果进行mask
 - encoder：没有mask，token可以和任意位置的词计算注意力
 - decoder:只保留下三角的数据，上三角进行mask。token只和之前词计算注意力
 - Prefix:保留T型结构的数据，部分全可见，部分保留下三角。
 - 适用于seq2seq任务，例如：翻译。原句seq保持可见，翻译部分seq按照decoder的形式来。



- 主流nlp模型架构：
 - Encoder-only：代表BERT，做文本理解任务
 - Decoder-only**:代表GPT，做生成任务，**主流大模型**
 - Encoder+Decoder:同时包含两种结构，计算量过大，做理解+生成任务
 - Prefix：代表GLM，也是做理解+生成任务

架构类型	Encoder-only	Decoder-only	Encoder-Decoder	Prefix LM
Mask 类型	全可见	Causal (下三角)	Encoder 双向 + Decoder 因果	前缀双向 + 后缀因果
代表模型	BERT RoBERTa ELECTRA	GPT-3/4 Llama Claude	T5 BART mT5	GLM ChatGLM
典型任务	文本分类 NER 句子相似度	对话 续写 开放生成	机器翻译 摘要 改写	统一框架 理解 + 生成

本课后续只聚焦 Decoder-only 这一主流路线 (GPT、Llama、Claude 全部属于此类)

- LLM模型完整推理过程：如下所示，模型会将生成的token拼接在原输入中，作为下一次的循环的输入，不断预测直到结束符。




大模型训练过程

- 如下所示, 交付一个大模型一般需要如下过程: 预训练-->SFT-->对齐




- 预训练:
 - 训练: 在海量无标注文本数据上进行 Next-Token Prediction 训练, 即根据前文预测下一个 token, 并对序列中的预测位置计算 loss。
 - 目标: 让模型学会语言规律、通用知识和基础推理能力, 形成通用的文本生成与理解能力。
- SFT:
 - 训练: 精标数据上做监督学习, 通常输入是指令/问题, 输出是期望回答; 训练时一般只对 assistant 回复部分计算 loss, prompt 部分不计 loss。
 - 目标: 让模型学会遵循指令、按照任务要求输出, 并形成特定的回答风格与任务能力
- 对齐:
 - 训练: 基于人类偏好数据或其他反馈信号进行偏好学习, 使模型更倾向于输出被偏好的回答。常见方法包括 RLHF、DPO 等。
 - 目标: 让模型输出更有帮助、更安全、更符合人类偏好和使用要求

预训练阶段的 Loss 计算




SFT 阶段的 Loss 计算



采样策略

- 概念：LLM输出tokens向量，如何进行选择token的方法。
- 维度1
 - Temperature 温度：在模型softmax添加超参数： $P(i) = \text{softmax}(\text{logits}/T)$ ，通过控制T值控制概述输出分布的离散程度



- 维度2
 - TOP K
 - 策略：只保留K个概率最大的token，舍弃其它token，并重新归一化
 - 优点：切除长尾token，保障结果稳定性
 - 缺点：K值难以确定，固定K值一刀切，不适配概率分布
 - TOP P
 - 策略：按概率从大到小排序，选累积概率第一次达到 P 的最小集合，再重新归一化
 - 优点：适配分布概率分布，一般比TOP K更常用
- 维度3
 - 贪心策略：
 - 策略：选择概率最高的token

- 优点：结果确定，可复现
- 缺点：容易陷入重复，局部最优


束搜索(Beam Search)

- 策略：保留概率最大的K条路径，每次自回归的时候，输入K个路径的结果，再更新最新的K个路径，最终选择概率最大的路径。
- 优点：质量高
- 缺点：计算开销乘K倍


概率采样

- 策略：根据token概率分布进行随机采

示例 (从 5 个候选中选)



选中：“真” ($p = 0.45$ 最大)
无论运行多少次，结果永远一样



最优路径：start $\rightarrow$ A(0.5) $\rightarrow$?(0.4)
累积概率 = $0.5 \times 0.4 = 0.20$, 比 greedy 更稳

常用策略组合

- 贪心：用于确定性强问题，例如：代码，数学生成
- Beam Search:更常见于传统序列生成任务，如机器翻译、语音识别
- Temperature + TOP P+概率采样：**主流组合**，常规对话，助手等

LLM特点

In-Context Learning(ICL):

- 概念：模型无需更新任何权重，仅凭 Prompt 中提供的若干示例，就能学会完成全新任务。
- 案例：如下所示，通过在prompt中添加案例，即可优化输出结果。
- 对比传统npl优势：传统nlp是专用模型，泛化能力差，一个模型针对一个任务，不同任务需要重新训练模型。LLM通过修改prompt就能完成不同任务，具有决定性优势。

Zero-shot	One-shot	Few-shot
仅描述任务，不给任何示例	给出一个示例后再提问	给出多个示例（通常 2~8 个）
Prompt Classify sentiment: Text: I love this product Sentiment:	Prompt Translate EN to FR: sea otter => loutre de mer cheese =>	Prompt Q: 2+3=? A: 5 Q: 4*5=? A: 20 Q: 7-2=? A:
=> Positive	=> fromage	=> 5
纯靠任务描述，依赖模型内部知识	一个例子显著提升格式遵从性	更多示例进一步提升精度和稳定性

思维链 Chain-of-Thought(COT):

- 概念：在 Prompt 中提供带有中间推理步骤的示例，引导模型展示完整的推理过程，而不是直接跳到最终答案，有助于提升模型效果。
- 案例：如下所示

标准 Few-shot（无推理链）	CoT Few-shot（含推理链）
Q: Roger有5个球，再买了2盒，每盒3个。他共有多少球？ A: 11 Q: 食堂有23个苹果，他们用了20个做午饭，又买了6个。还剩多少个苹果？ A: ???	Q: Roger有5个球，再买了2盒，每盒3个。他共有多少球？ A: 2盒*3=6个，5+6=11个。答案是11。 Q: 食堂有23个苹果，他们用了20个做午饭，又买了6个。还剩多少个苹果？ A: ???
=> 27 （错误）	=> 23-20+6=9 （正确）

Scaling Law

- 概念：语言模型的性能与参数量、训练数据量、计算量之间存在稳定的幂律关系——三者增加，性能可预测地提升。
- 特点：随着模型参数，训练数据，训练时使用的算力(训练轮次)越大，模型能力越强。当然有边界，同时也取决于模型结构是否合理。
- 特点：同时例如ICL和COT等能力，也是在模型参数达到一定规模后才能出现，在小模型上几乎不存在。

参数量 N	数据量 D	算力 C	In-Context Learning	Chain-of-Thought
$L(N) = (N_c/N)^{\alpha}$	$L(D) = (D_c/D)^{\alpha}$	$L(C) = (C_c/C)^{\alpha}$	阈值: ~100B params ICL 能力在小模型上几乎不存在，175B GPT-3 首次明显呈现	阈值: >100B params 小模型做 CoT 反而更差，在 PaLM 540B 上才见到明显效果
N 越大，Loss 越低 	D 越大，Loss 越低 	C 越大，Loss 越低 	多步数学推理 阈值: ~100B params 如 GSM8K 等数学题，在参数不足时准确率接近随机猜测	指令遵从能力 阈值: ~100B + RLHF 仅规模不够，还需要对齐训练（RLHF），才能稳定遵从复杂指令
结论：只要持续扩大三个要素，Loss 就会以幂律速度下降——而且这条规律跨越了多个数量级都成立				

